

第9周讲稿

应用举例：唯一性定理和连续性定理的应用

例1 对于依赖于参数 λ 的随机变量族 $X_\lambda \sim P(\lambda)$, 证明: 其标准化随机变量

$$\frac{X_\lambda - \lambda}{\sqrt{\lambda}} \xrightarrow{D} N(0,1) \quad \lambda \rightarrow \infty$$

证明: 由于 $\frac{X_\lambda - \lambda}{\sqrt{\lambda}}$ 的特征函数为

$$\begin{aligned}\varphi_{\frac{X_\lambda - \lambda}{\sqrt{\lambda}}}(\theta) &= e^{-i\sqrt{\lambda}\theta} \varphi_{X_\lambda}\left(\frac{\theta}{\sqrt{\lambda}}\right) \\&= e^{-i\sqrt{\lambda}\theta} \exp(\lambda(e^{i\frac{\theta}{\sqrt{\lambda}}} - 1)) \\&= e^{-i\sqrt{\lambda}\theta} \exp(\lambda(i\frac{\theta}{\sqrt{\lambda}} - \frac{1}{2}\frac{\theta^2}{\lambda} + o(\frac{1}{\lambda}))) \quad (\lambda \rightarrow \infty) \\&= \exp(-\frac{\theta^2}{2} + o(1)) \rightarrow e^{-\frac{\theta^2}{2}}.\end{aligned}$$

即: 当 $\lambda \rightarrow \infty$ 时, 其极限是 $N(0,1)$ 的特征函数. 故由唯一性定理和连续性定理可知

$$P\left(\frac{X_\lambda - \lambda}{\sqrt{\lambda}} \leq x\right) \rightarrow \Phi(x) \quad (\lambda \rightarrow \infty),$$

其中 $\Phi(x)$ 是标准正态随机变量的分布函数.

例2 设 X_1, X_2, \dots, X_n 相互独立, 且 $X_i \sim N(\mu_i, \sigma_i^2) \quad i=1, 2, \dots, n$, 则

$$X = a_1 X_1 + a_2 X_2 + \dots + a_n X_n + b \sim N\left(\sum_{i=1}^n a_i \mu_i + b, \sum_{i=1}^n a_i^2 \sigma_i^2\right)$$

3. 随机向量的特征函数

(A) 定义 设 $X = (X_1, X_2, \dots, X_m)^T$ 是一个 m 维随机向量, $\theta = (\theta_1, \theta_2, \dots, \theta_m)^T$ 表示 \mathbf{R}^m 中的实向量, 则 m 元函数

$$\varphi(\theta) = \varphi(\theta_1, \theta_2, \dots, \theta_m) = Ee^{i\theta^T X}$$

称为 X 的特征函数, 或称为 X_1, X_2, \dots, X_m 的联合特征函数 (对应与分析中的多元 Fourier

变换)

(B) 性质 (类似一维情形)

需要重点指出的是如下几点:

(1) (求混合矩的公式) 若 $E|X_1^{k_1} X_2^{k_2} \cdots X_m^{k_m}| < \infty$, 则

$$E(X_1^{k_1} X_2^{k_2} \cdots X_m^{k_m}) = (-i)^{k_1+\cdots+k_m} \frac{\partial^{k_1+\cdots+k_m}}{\partial^{k_1} x_1 \cdots \partial^{k_m} x_m} \varphi(0, \cdots, 0)$$

(2) (线性变换的特征函数公式) 设 \mathbf{B} 是一个 $l \times m$ 矩阵, \mathbf{b} 为 l 维列向量, $\boldsymbol{\theta} = (\theta_1, \cdots, \theta_l)^T$

为 l 维列向量, 那么 $\mathbf{BX} + \mathbf{b}$ 的特征函数 (l 维) 为 $\varphi_{\mathbf{BX}+\mathbf{b}}(\boldsymbol{\theta}) = e^{i \boldsymbol{\theta}^T \mathbf{b}} \varphi_{\mathbf{X}}(\mathbf{B}^T \boldsymbol{\theta})$ 。

(3) (独立性判断定理) 设 $\varphi(\theta_1, \theta_2, \cdots, \theta_m)$ 为 m 维随机向量 $(X_1, X_2, \cdots, X_m)^T$ 的特征函数, $\varphi_{X_i}(\theta_i)$ 为 X_i 的特征函数, $i = 1, 2, \cdots, m$. 那么 X_1, X_2, \cdots, X_m 相互独立的充要条件为

对一切 $\theta_1, \theta_2, \cdots, \theta_m$, 有 $\varphi(\theta_1, \theta_2, \cdots, \theta_m) = \varphi_{X_1}(\theta_1) \varphi_{X_2}(\theta_2) \cdots \varphi_{X_m}(\theta_m)$

注: 推广到随机向量的独立性判断: 设 $\varphi_X(\theta_1, \theta_2, \cdots, \theta_m)$ 为 m 维随机向量 $(X_1, X_2, \cdots, X_m)^T$ 的特征函数, $\varphi_Y(\theta_{m+1}, \theta_{m+2}, \cdots, \theta_{m+n})$ 为 n 维随机向量 $(Y_1, Y_2, \cdots, Y_n)^T$ 的特征函数, $\varphi(\theta_1, \theta_2, \cdots, \theta_{m+n})$ 为 $n+m$ 维随机向量 $(X_1, X_2, \cdots, X_m, Y_1, Y_2, \cdots, Y_n)^T$ 的特征函数. 那么随机向量 (X_1, X_2, \cdots, X_m) 与随机向量 (Y_1, Y_2, \cdots, Y_n) 相互独立的充要条件为对一切 $\theta_1, \theta_2, \cdots, \theta_{m+n}$, 有 $\varphi(\theta_1, \theta_2, \cdots, \theta_{m+n}) = \varphi_X(\theta_1, \cdots, \theta_m) \varphi_Y(\theta_{m+1}, \cdots, \theta_{m+n})$

§2 多维 Gauss 分布, 多维正态分布及其特征函数

1. 多维 Gauss 分布的定义

定义 设 n 个相互独立的随机变量 Z_1, Z_2, \cdots, Z_n 均服从标准正态分布, 如果存在常数 a_{ij} ($1 \leq i \leq m, 1 \leq j \leq n$) 与 μ_i ($1 \leq i \leq m$) 使得

$$X_1 = a_{11}Z_1 + \cdots + a_{1n}Z_n + \mu_1$$

$$X_2 = a_{21}Z_1 + \cdots + a_{2n}Z_n + \mu_2$$

$$\vdots$$

$$X_i = a_{i1}Z_1 + \cdots + a_{in}Z_n + \mu_i$$

$$\vdots$$

$$X_m = a_{m1}Z_1 + \cdots + a_{mn}Z_n + \mu_m$$

即 $X = AZ + \mu$ (这里 $A = (a_{ij})_{m \times n}$)

称由 X_1, X_2, \cdots, X_m 构成的 m 维随机向量 $X = (X_1, X_2, \cdots, X_m)^T$ 服从 m 维 (或 m 元) Gauss 分布。特别地, 当矩阵 A 的秩为 m 时 (即 $m \leq n$, 且 A 为满秩的情形), 称 m 维随机向量 $X = (X_1, X_2, \cdots, X_m)^T$ 服从 m 维 (或 m 元) 联合正态分布, 简称 m 维正态分布。

注: (1) m 维 Gauss 分布的一维边缘分布为一维 Gauss 分布 (或为一维正态, 或为常数)。

(2) 设 $X = (X_1, X_2, \cdots, X_m)^T$ 为 Gauss 随机向量, 则有

$$\text{期望向量 } EX = (EX_1, EX_2, \cdots, EX_m)^T = (\mu_1, \cdots, \mu_m)^T = \mu;$$

协方差矩阵为 $\Sigma = (Cov(X_i, X_j))_{m \times m}$, 其中

$$\begin{aligned} Cov(X_i, X_j) &= Cov\left(\sum_{k=1}^n a_{ik}Z_k + \mu_i, \sum_{l=1}^n a_{jl}Z_l + \mu_j\right) \\ &= Cov\left(\sum_{k=1}^n a_{ik}Z_k, \sum_{l=1}^n a_{jl}Z_l\right) \\ &= \sum_{k,l} a_{ik}a_{jl}Cov(Z_k, Z_l) = \sum_{k=1}^n a_{ik}a_{jk} \end{aligned}$$

$$\text{即 } \Sigma = (Cov(X_i, X_j))_{i,j} = AA^T.$$

记此 m 维 Gauss 分布为 $X \sim N(\mu, \Sigma)$ (对应于一维正态)。

(3) Gauss 分布 $X \sim N(\mu, \Sigma)$ 是正态分布的充要条件是矩阵 Σ 的行列式非 0, 即不退化 (即 Σ 正定时)。

2. m 维 Gauss 随机变量 $X \sim N(\mu, \Sigma)$ 的特征函数

定理 m 维 Gauss 分布 $N(\mu, \Sigma)$ 的 (m 维) 特征函数为

$$\varphi(\theta) = \exp\{i\theta^T \mu - \frac{1}{2}\theta^T \Sigma \theta\}.$$

反之也成立。

定义 (多维 Gauss 分布的等价定义) m 维随机向量 $X = (X_1, X_2, \cdots, X_m)^T$ 称为服从 Gauss 分布, 如果它的特征函数有如下形式

$$\varphi(\theta) = \varphi(\theta_1, \theta_2, \cdots, \theta_m) = \exp\{i\theta^T \mu - \frac{1}{2}\theta^T \Sigma \theta\} \quad (5.10)$$

其中 μ 为 m 维列向量, Σ 为 $m \times m$ 的非负定矩阵. 特别, 当 Σ 是正定矩阵时, 称它服从 m 维正态分布。

推论 多维 Gauss 随机向量经过线性变换仍然是 Gauss 随机向量, 即若 $X \sim N(\mu, \Sigma)$, B 为

$n \times m$ 矩阵, \mathbf{b} 为 n 维列向量, 那么

$$\mathbf{B}\mathbf{X} + \mathbf{b} \sim N(\mathbf{B}\boldsymbol{\mu} + \mathbf{b}, \mathbf{B}\boldsymbol{\Sigma}\mathbf{B}^T)$$

3. m 维 Gauss 随机变量 $\mathbf{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 的性质

定理 1 (分量独立问题) 设 $\mathbf{X} = (X_1, X_2, \dots, X_m)^T$ 为 m 维 Gauss 随机向量, 则 X_1, X_2, \dots, X_m 相互独立的充要条件为 $\text{Cov}(X_i, X_j) = 0 \quad 1 \leq i \neq j \leq m$, 即协方差矩阵是对角型的.

定理 1' 若 $(X_1, \dots, X_{m+n})^T$ 服从 Gauss 分布, 则 $(X_1, \dots, X_n)^T$ 与 $(X_{n+1}, \dots, X_{n+m})^T$ 相互独立的充要条件是

$$\sigma_{ij} = 0 \quad (i \leq n, j > n),$$

其中

$$\boldsymbol{\Sigma} = (\sigma_{kl}) \quad (k, l = 1, \dots, n+m)$$

是 $(X_1, \dots, X_{m+n})^T$ 的协方差矩阵. 而以上条件的含义是说, 协方差矩阵是准对角型的.

推论: 设 $\mathbf{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, 则 $\mathbf{A}\mathbf{X}$ 与 $\mathbf{B}\mathbf{X}$ 独立当且仅当 $\mathbf{A}\boldsymbol{\Sigma}\mathbf{B}^T = \mathbf{0}$. (\mathbf{A} 为 $(m-p) \times m$, \mathbf{B} 为 $p \times m$) (思考)

定理 2 m 维随机向量 $\mathbf{X} = (X_1, X_2, \dots, X_m)^T$ 为 Gauss 的, 当且仅当对于任意一个 m 维向量 $\mathbf{a} = (a_1, a_2, \dots, a_m)^T$, $\mathbf{a}^T \mathbf{X}$ 为一维 Gauss 随机变量.

证明 必要性显然. 充分性的证明如下: 如果对任意的常数向量 \mathbf{a} , 线性组合 $Y = \mathbf{a}^T \mathbf{X}$ 都服从一维正态分布. 那么我们有

$$EY = \mathbf{a}^T \boldsymbol{\mu}, DY = \mathbf{a}^T \boldsymbol{\Sigma} \mathbf{a}.$$

由假定 Y 是 Gauss 的, 因此其特征函数为

$$Ee^{i\theta Y} = \exp\{i\theta \mathbf{a}^T \boldsymbol{\mu} - \frac{1}{2} \theta^2 \mathbf{a}^T \boldsymbol{\Sigma} \mathbf{a}\}.$$

令 $\theta=1$ 即得

$$E \exp\{i \mathbf{a}^T \mathbf{X}\} = \exp\{i \mathbf{a}^T \boldsymbol{\mu} - \frac{1}{2} \mathbf{a}^T \boldsymbol{\Sigma} \mathbf{a}\}.$$

这就是 m 维 Gauss 分布 $N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 的特征函数.

注: 多维 Gauss 随机向量的研究可以转化为对一维 Gauss 随机变量的研究。

定义 (多维 Gauss 分布的第 2 个等价定义) m 维随机向量 $\mathbf{X} = (X_1, X_2, \dots, X_m)^T$ 称为

Gauss 的, 如果对于任意一个 m 维向量 $\mathbf{a} = (a_1, a_2, \dots, a_m)^T$, 一维随机变量 $\mathbf{a}^T \mathbf{X}$ 要么是正

态的, 要么是常数.

定理 3 (多维正态分布的等价定义) 正态分布具有分布密度. 即若 $\mathbf{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, 其行列式 $|\boldsymbol{\Sigma}| > 0$, 则对任意 $\mathbf{x} = (x_1, x_2, \dots, x_m)$, \mathbf{X} 的联合概率密度函数为

$$f(\mathbf{x}) = f(x_1, x_2, \dots, x_m) = \left(\frac{1}{2\pi}\right)^{\frac{m}{2}} \frac{1}{\sqrt{|\boldsymbol{\Sigma}|}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right\}$$

称为 m 维正态密度.

证明 由于 $\boldsymbol{\Sigma}$ 非退化, 即它是正定的, 由线性代数知道必存在一个对称的可逆矩阵 $\boldsymbol{\Lambda}$, 使 $\boldsymbol{\Sigma} = \boldsymbol{\Lambda}\boldsymbol{\Lambda}^T$. 作变量替换

$$\mathbf{y} (= \mathbf{y}(\mathbf{x})) = \boldsymbol{\Lambda}^{-1}(\mathbf{x} - \boldsymbol{\mu}),$$

其 Jacobian 是 $\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \boldsymbol{\Lambda}^{-1}$, 故其行列式的绝对值为 $|\boldsymbol{\Lambda}^{-1}| = \frac{1}{\sqrt{|\boldsymbol{\Sigma}|}}$.

而随机向量 \mathbf{X} 的线性变换 $\mathbf{Y} = \boldsymbol{\Lambda}^{-1}(\mathbf{X} - \boldsymbol{\mu})$, 则

$$\mathbf{Y} \sim N(\mathbf{0}, \boldsymbol{\Lambda}^{-1}\boldsymbol{\Sigma}(\boldsymbol{\Lambda}^{-1})^T) = N(\mathbf{0}, \mathbf{I}),$$

即它的分量是相互独立的标准正态随机变量, 故它有分布密度

$$f_{\mathbf{Y}}(\mathbf{y}) = \frac{1}{\sqrt{2\pi}} e^{-\frac{y_1^2}{2}} \cdots \frac{1}{\sqrt{2\pi}} e^{-\frac{y_m^2}{2}} = \left(\frac{1}{2\pi}\right)^{\frac{m}{2}} e^{-\frac{1}{2}\mathbf{y}^T \mathbf{y}}.$$

所以 \mathbf{X} 有分布密度 (直观地: $f_{\mathbf{Y}}(\mathbf{y}) d\mathbf{y} = f(\mathbf{x}) d\mathbf{x}$, 即 $f(\mathbf{x}) = f_{\mathbf{Y}}(\mathbf{y}(\mathbf{x})) \left| \frac{\partial \mathbf{y}}{\partial \mathbf{x}} \right|$)

$$f(\mathbf{x}) = \left(\frac{1}{2\pi}\right)^{\frac{m}{2}} \frac{1}{\sqrt{|\boldsymbol{\Sigma}|}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right\}.$$

注: 对照二维情形.

§3 Brown 运动以及它的分布

1. Einstein 的模型

作随机运动的粒子在时间 $[0, t]$ 上的位移为 $\{B_s : 0 \leq s \leq t\}$ (初始位置 $B_0 = 0$)

假设: (1) 粒子位移的各分量都相互独立. (i.e. 各分量为独立增量过程);

(2) 运动的统计规律对空间是对称的, i.e. $EB_t = 0$;

(3) 增量 $B_{t+h} - B_h$ 的分布与 h 无关 (i.e. 时齐), 且 $\sigma(t) \equiv E(B_{t+h} - B_h)^2$ 存在, 而

且是 t 的连续函数. ($\Rightarrow \sigma(t+s) = \sigma(t) + \sigma(s) \Rightarrow \sigma(t) = Dt$)

结论： $\{B_t : t \geq 0\}$ 为时齐的独立增量过程，其的一维分布为 $N(0, Dt)$ 。

理由： 如记 B_t 的特征函数为 $\varphi(t, \theta) = Ee^{i\theta B_t} (-\infty < \theta < \infty)$ ，则

$$\begin{aligned}\varphi(t+s, \theta) - \varphi(t, \theta) &= Ee^{i\theta B_{t+s}} - Ee^{i\theta B_t} \\ &= E[e^{i\theta B_t}(e^{i\theta(B_{t+s}-B_t)} - 1)] = E[e^{i\theta(B_t-B_0)}(e^{i\theta(B_{t+s}-B_t)} - 1)] \\ &= E(e^{i\theta(B_t-B_0)})E(e^{i\theta(B_{t+s}-B_t)} - 1) = E(e^{i\theta B_t})E(e^{i\theta(B_s-B_0)} - 1) \\ &= \varphi(t, \theta)E(e^{i\theta B_s} - 1). \\ \Rightarrow \frac{\partial \varphi}{\partial t}(t, \theta) &= -\frac{1}{2}D\theta^2\varphi(t, \theta) \\ \varphi(0, \theta) &= 1\end{aligned}$$

解得 $\varphi(t, \theta) = e^{-\frac{1}{2}\theta^2 Dt}$ 。

2. Brown 的定义

定义：Brown 运动 定义为满足以下条件的一个随机过程 $B = \{B_t, t \geq 0\}$ ：

- (1) B 是独立增量过程，即对任意互不相交的区间 $(s_1, t_1], (s_2, t_2], \dots, (s_n, t_n]$ ，其上的增量 $B_{t_1} - B_{s_1}, B_{t_2} - B_{s_2}, \dots, B_{t_n} - B_{s_n}$ 都相互独立；
- (2) 对于任意 $s \geq 0, t > 0$ ，增量 $B_{s+t} - B_s \sim N(0, Dt)$ （不依赖 s ）；
- (3) 对每一个固定的 ω ， $B_t(\omega)$ 是 t 的连续函数（此条件不是必需的）。

特别，当 $D=1$ 时，我们称之为**标准 Brown 运动**。以下研究的 Brown 运动均为**标准 Brown 运动**。

注：(1) **Markov 性**：已知现在 B_s 的条件下，过去 B_u ($0 \leq u < s$) 与将来 B_{t+s} 是相互独立的；

(2) B 的任意有限维分布为

$$\begin{aligned}P(\omega : B_{t_1} \leq x_1, \dots, B_{t_n} \leq x_n) &= \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_n} f(u_1, u_2, \dots, u_n) du_1 \dots du_n \\ &= \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_n} \frac{\exp\left\{-\left(\frac{u_1^2}{2t_1} + \frac{(u_2-u_1)^2}{2(t_2-t_1)} + \dots + \frac{(u_n-u_{n-1})^2}{2(t_n-t_{n-1})}\right)\right\}}{(2\pi)^{\frac{n}{2}} \sqrt{t_1(t_2-t_1) \dots (t_n-t_{n-1})}} du_1 \dots du_n\end{aligned}$$

(3) Brown 运动是一个 Gauss 过程

Gauss 过程的定义： 一个实值连续时间过程 X 称为 **Gauss 过程**，如果每一有限维向量 $(X(t_1), X(t_2), \dots, X(t_n))^T$ 均服从 Gauss 分布 $N(\boldsymbol{\mu}(t), \mathbf{R}(t))$ ，其中的均值向量 $\boldsymbol{\mu}$ 和协方差矩阵 \mathbf{R} 均依赖于 $t = (t_1, t_2, \dots, t_n)$ 。