

# 第 13 周讲稿 UMVUE 和有效估计

## UMVUE 和有效估计

★  $\theta^*$  是  $\theta$  的无偏估计, 若对于  $\theta$  的任意一个无偏估计量  $\theta$ , 有  $D\theta^* \leq D\theta$ , 则  $\theta^*$  是  $\theta$  的最小方差无偏估计, 记 MVUE 或 UMVUE (uniformly minimum-variance unbiased estimator)

注: 这里一致是指  $\forall \theta \in \Theta$ 。

★ 重要的定理 (Rao-Blackwell 定理)

定理: 随机变量  $X$  的方差存在, 令  $\varphi(Y) = E(X | Y)$ , 则

$$E[\varphi(Y)] = EX, D[\varphi(Y)] \leq DX$$

且等号成立当且仅当  $P(X = \varphi(Y)) = 1$ 。

证明: 不妨设  $EX = 0$ , 则

$$\begin{aligned} D[\varphi(Y)] &= E[\varphi(Y)]^2 \\ &= E[E(X | Y)]^2 \\ &= E\{[E(X | Y)][E(X | Y)]\} \\ &= E[E(XE(X | Y) | Y)] \\ &= E(XE(X | Y)) \\ &\leq \sqrt{EX^2 E[E(X | Y)]^2} \end{aligned}$$

从而  $D[\varphi(Y)] = E[E(X | Y)]^2 \leq EX^2 = DX$

注: 可以直接利用  $DX = D[E(X | Y)] + E[D(X | Y)]$ 。

★ 推论: 若  $T = T(X_1, X_2, \dots, X_n)$  为  $\theta$  的充分统计量,  $\hat{\theta}$  为  $\theta$  的任一无偏估计量, 则  $\tilde{\theta} = E(\hat{\theta} | T)$  也为  $\theta$  的无偏估计量, 且  $D(\tilde{\theta}) \leq D\hat{\theta}$ 。

例: 设  $X_1, X_2, \dots, X_n$  是总体  $X \sim B(1, p), 0 < p < 1$  (即 Bernoulli 分布) 的一个样本, 显然估计量  $X_1$  是  $p$  的无偏估计。我们用 Rao-Blackwell 定理求  $p$

的改进的无偏估计量。

由于  $T = \sum_{i=1}^n X_i$  为  $p$  的充分统计量，由于  $X_1$  只取 0 和 1 两个值，故

$$\begin{aligned}
 E[X_1 | T = t] &= P(X_1 = 1 | T = t) \\
 &= \frac{P(X_1 = 1, T = t)}{P(T = t)} \\
 &= \frac{P(X_1 = 1, X_2 + X_3 + \cdots + X_n = t - 1)}{P(T = t)} \\
 &= \frac{P(X_1 = 1)P(X_2 + X_3 + \cdots + X_n = t - 1)}{P(T = t)} \\
 &= \frac{p C_{n-1}^{t-1} p^{t-1} (1-p)^{n-1-(t-1)}}{C_n^t p^t (1-p)^{n-t}} \\
 &= \frac{t}{n}
 \end{aligned}$$

故由 Rao-Blackwell 定理知

$$E[X_1 | T] = \frac{T}{n} (= \bar{X}) \text{ 是 } p \text{ 的改进的无偏估计量。}$$

注：利用对称性直接可知， $E[X_1 | T] = E[X_1 | \sum_{i=1}^n X_i] = \frac{\sum_{i=1}^n X_i}{n}$ 。

★ UMVUE 的一个判别准则：零无偏估计定理

如果 UMVUE 存在，则由 Rao-Blackwell 定理的推论知，它一定是充分统计量的函数。

零无偏估计量是指期望为 0 的统计量。

定理（零无偏估计定理）如果  $\hat{\theta}$  是  $\theta$  的方差有限的无偏估计量，且对任何零无偏估计量  $\varphi = \varphi(X_1, \cdots, X_n)$ ，都有

$$Cov_{\theta}(\hat{\theta}, \varphi) = 0, \forall \theta \in \Theta$$

则  $\hat{\theta}$  是  $\theta$  的 UMVUE。

证明：对  $\theta$  的任意一个无偏估计量  $\tilde{\theta}$ ，显然  $\varphi \triangleq \tilde{\theta} - \hat{\theta}$  为零无偏估计量，且

$$\begin{aligned}
D(\tilde{\theta}) &= D(\hat{\theta} + \varphi) = D(\hat{\theta}) + D(\varphi) + 2Cov(\hat{\theta}, \varphi) \\
&= D(\hat{\theta}) + D(\varphi) \geq D(\hat{\theta}), \forall \theta \in \Theta
\end{aligned}$$

例：设  $X \sim E(\frac{1}{\theta})$ ，参数  $\theta$  未知， $X_1, X_2, \dots, X_n$  是其容量为  $n$  的样本。则  $\bar{X}$  为  $\theta$  的 **UMVUE**。

解：由因子分解定理， $T = T(X_1, X_2, \dots, X_n) = \sum_{i=1}^n X_i$  为  $\theta$  的充分统计量，

$\bar{X} = \frac{T}{n}$  为  $\theta$  的无偏估计量。设任何零无偏估计量  $\varphi = \varphi(X_1, \dots, X_n)$ ，由于

$$E\varphi = \int_0^\infty \cdots \int_0^\infty \varphi(x_1, \dots, x_n) \prod_{i=1}^n \left[ \frac{e^{-\frac{x_i}{\theta}}}{\theta} \right] dx_1 \cdots dx_n = 0$$

$$\text{即 } \int_0^\infty \cdots \int_0^\infty \varphi(x_1, \dots, x_n) e^{-\sum_{i=1}^n \frac{x_i}{\theta}} dx_1 \cdots dx_n = 0$$

两边对  $\theta$  求导得

$$\int_0^\infty \cdots \int_0^\infty \frac{n\bar{X}}{\theta^2} \varphi(x_1, \dots, x_n) e^{-\sum_{i=1}^n \frac{x_i}{\theta}} dx_1 \cdots dx_n = 0$$

即  $E(\bar{X}\varphi) = 0$ ，即  $Cov(\bar{X}, \varphi) = 0$ ，故  $\bar{X}$  为  $\theta$  的 **UMVUE**。

## Cremer-Rao 不等式和有效估计

### ★ Fisher 信息量:

设总体的密度函数 (或 pmf)  $f(x; \theta)$ ,  $\theta \in \Theta$  满足下列条件:

- 1) 参数空间  $\Theta$  是直线上的一个开区间;
- 2) 支撑  $S = \{x: f(x; \theta) > 0\}$  与  $\theta$  无关;
- 3) 导数  $\frac{\partial}{\partial \theta} f(x; \theta)$  对一切  $\theta \in \Theta$  都存在;
- 4) 对  $f(x; \theta)$ , 积分与微分运算可交换次序, 即

$$\frac{\partial}{\partial \theta} \int_{-\infty}^{\infty} f(x; \theta) dx = \int_{-\infty}^{\infty} \frac{\partial}{\partial \theta} f(x; \theta) dx,$$

- 5) 期望  $I(\theta) = E \left[ \frac{\partial}{\partial \theta} \ln f(X; \theta) \right]^2$  存在。

则称该期望  $I(\theta)$  为总体分布的 **Fisher** 信息量。

注: 如果二阶导数对一切  $\theta \in \Theta$  都存在, 则  $I(\theta)$  还可以用下式计算

$$I(\theta) = -E \left[ \frac{\partial^2}{\partial \theta^2} \ln f(X; \theta) \right]$$

### ★ Cremer-Rao 不等式

设  $X_1, X_2, \dots, X_n$  为取自具有 pdf (或 pmf)  $f(x; \theta)$ ,  $\theta \in \Theta = \{\theta: a < \theta < b\}$  的总体  $X$  的一个样本,  $a, b$  为已知常数,  $a$  可以取  $-\infty$ ,  $b$  可以取  $+\infty$ 。又  $\eta = \eta(X_1, X_2, \dots, X_n)$  是  $g(\theta)$  的一个无偏估计, 且满足正则条件:

- 1) 集合  $\{x: f(x; \theta) > 0\}$  与  $\theta$  无关;
- 2)  $g'(\theta)$  与  $\frac{\partial f(x; \theta)}{\partial \theta}$  存在, 且对一切  $\theta \in \Theta$ ,

$$\frac{\partial}{\partial \theta} \int f(x; \theta) dx = \int \frac{\partial f(x; \theta)}{\partial \theta} dx,$$

$$\begin{aligned} & \frac{\partial}{\partial \theta} \int \int \cdots \int \eta(x_1, x_2, \dots, x_n) f(x_1; \theta) f(x_2; \theta) \cdots f(x_n; \theta) dx_1 dx_2 \cdots dx_n \\ &= \int \int \cdots \int \eta(x_1, x_2, \dots, x_n) \frac{\partial}{\partial \theta} \left[ \prod_{i=1}^n f(x_i; \theta) \right] dx_1 dx_2 \cdots dx_n; \end{aligned}$$

$$3) \text{ 令 } I(\theta) = E_{\theta} \left( \frac{\partial \ln f(X; \theta)}{\partial \theta} \right)^2 > 0,$$

$$\text{则 } D_{\theta} \eta \geq \frac{[g'(\theta)]^2}{nI(\theta)} \quad (*)$$

并且存在一个有可能依赖于  $\theta$  但不依赖于  $X_1, X_2, \dots, X_n$  的数  $K$ , 使得等式

$$\sum_{i=1}^n \frac{\partial \ln f(X_i; \theta)}{\partial \theta} = K(\eta - g(\theta)) \text{ 以概率 } 1 \text{ 成立, 以上这个条件为式 } (*) \text{ 中等式成}$$

立的充要条件。特别地当  $g(\theta) = \theta$  时, 不等式  $(*)$  化为

$$D_{\theta} \eta \geq \frac{1}{nI(\theta)}.$$

[注]1. 若  $\xi$  是离散型随机变量,  $f(x; \theta)$  则表示为  $P(\xi = x; \theta)$ , 相应的积分号改为求和号。

2. 在使用 **R-C** 不等式时可不必验证 2) 是否成立, 因为在一般情况下, 当 1) 成立时 2) 自动满足。

3. 满足 1)、2) 假定的估计量称为正则估计。

4. **R-C** 下界  $\frac{[g'(\theta)]^2}{nI(\theta)}$  不是所有无偏估计的下界, 而是无偏估计类中一个子

集——正则无偏估计的方差下界。

5. **R-C** 的重要作用——达到 **R-C** 下界的估计量一定是 **UMVUE**. 反之不然。即 **UMVUE** 不一定达到 **R-C** 下界。

6.  $I(\theta)$  信息量的意义

当  $D_{\theta} \eta = \frac{1}{nI(\theta)}$   $I(\theta)$  越大,  $D_{\theta}(\eta)$  越小估计精度高, 而  $I(\theta)$  大, 则认为模型本身所含的信息量较多, 或者说  $\theta$  易认识, 所以可视  $I(\theta)$  反应了模型中含有信息的量。

7. 若 **C-R** 不等式的等号成立 (达到 **C-R** 下界), 则称  $\eta = \eta(X_1, X_2, \dots, X_n)$  是  $g(\theta)$  的有效估计, 有效估计一定是 **UMVUE**。

8. 设  $T_1, T_2$  为  $\theta$  的两个无偏估计, 其方差均存在, 称  $eff_{\theta}(T_1 | T_2) \triangleq \frac{D_{\theta}(T_2)}{D_{\theta}(T_1)}$

为  $T_1$  关于  $T_2$  的效率, 称  $T_1$  比  $T_2$  有效, 若  $eff_{\theta}(T_1 | T_2) > 1$ 。

若  $T$  为  $\theta$  的有效估计 (即  $D_{\theta}(T) = \frac{1}{nI(\theta)}$ ), 则定义  $\theta$  的无偏估计  $T_1$  的效率为

$$eff_{\theta}(T_1) = eff_{\theta}(T_1 | T) = \frac{D_{\theta}(T)}{D_{\theta}(T_1)} = \frac{1}{nI(\theta)D_{\theta}(T_1)}$$

故有效估计的效率为 1, 任一无偏估计的效率不超过 1。

例 设样本  $X_1, X_2, \dots, X_n$  是来自  $B(1, p)$ , 求  $p$  的 UMVUE。

解: 设总体分布为  $f(x; p) = p^x(1-p)^{1-x}$ ,  $x=0, 1, 0 < p < 1$ 。

易证  $\{f(x; p) | p \in p(0, 1)\}$  满足正则条件, 因为

$$I(p) = E_p \left[ \frac{\partial}{\partial p} \ln f(X, p) \right]^2 = E_p \left[ \frac{X-p}{p(1-p)} \right]^2 = \frac{1}{p^2(1-p)^2} E_p (X-p)^2 = \frac{1}{p(1-p)},$$

故  $\frac{1}{nI(p)} = \frac{p(1-p)}{n}$  为  $p$  的无偏估计的 C-R 下界;

$$\bar{X} \text{ 作为 } p \text{ 的无偏估计, 有: } D_p(\bar{X}) = \frac{1}{n^2} \sum_{i=1}^n D_p(X_i) = \frac{1}{n^2} np(1-p) = \frac{p(1-p)}{n},$$

$\bar{X}$  达到了 C-R 下界, 故  $\bar{X}$  为  $p$  的 UMVUE。

例 设总体  $X$  的密度函数为  $f(x; \lambda) = \begin{cases} \lambda e^{-\lambda x}, & x > 0; \\ 0, & x \leq 0; \end{cases}$  未知参数  $\lambda > 0$ , 总体的一个

样本为  $(X_1, X_2, \dots, X_n)$ , 证明  $\bar{X}$  是  $\frac{1}{\lambda}$  的一个 UMVUE。

证明: 由指数分布的总体满足正则条件可得:

$$I(\lambda) = -E \left[ \frac{\partial^2}{\partial \lambda^2} \ln f(X; \lambda) \right] = -E \left( \frac{-1}{\lambda^2} \right) = \frac{1}{\lambda^2},$$

$$\frac{\left[ \left( \frac{1}{\lambda} \right)' \right]^2}{nI(\lambda)} = \frac{\left[ \frac{-1}{\lambda^2} \right]^2}{n \frac{1}{\lambda^2}} = \frac{1}{n\lambda^2} \text{ 为 } \frac{1}{\lambda} \text{ 的无偏估计方差的 C-R 下界;}$$

另一方面  $E(\bar{X}) = \frac{1}{\lambda}$ ,  $V_{ar}(\bar{X}) = \frac{1}{n\lambda^2}$ ; 即  $\bar{X}$  的方差达到了 C-R 下界,

故  $\bar{X}$  是  $\frac{1}{\lambda}$  的一个 UMVUE。

## 完备统计量与 Lemann-Scheffe 定理

定义：称分布族  $\{f_\theta(x): \theta \in \Theta\}$  是完备的，若  $\forall \theta \in \Theta$ ,

$$E_\theta(g(X)) = 0 \Rightarrow P_\theta(g(X) = 0) = 1$$

定义：称统计量  $T = T(X_1, X_2, \dots, X_n)$  为完备的，若  $T$  的分布族是完备的。

注：完备分布族条件下， $E_\theta(g_1(X)) = E_\theta(g_2(X))$ ，则有

$$P_\theta(g_1(X) = g_2(X)) = 1$$

例：二项分布族  $\{B(n, p): 0 < p < 1\}$  ( $n$  已知) 是完备分布族。

证明：若  $E_p(g(X)) = \sum_{k=0}^n g(k) C_n^k p^k (1-p)^{n-k} = 0, \quad 0 < p < 1$

$$\text{则 } \sum_{k=0}^n g(k) C_n^k \left(\frac{p}{1-p}\right)^k = 0, \quad 0 < p < 1$$

等式左面是  $\frac{p}{1-p}$  的  $n$  次多项式，故  $g(k) = 0, k = 0, 1, 2, \dots, n$ ，证毕。

$$\star \prod_{i=1}^n f(x_i; \theta) = C(\theta) h(x_1, x_2, \dots, x_n) \exp\{b(\theta) T(x_1, x_2, \dots, x_n)\}$$

则  $T = T(x_1, x_2, \dots, x_n)$  是  $\theta$  的充分完备统计量

$$\star \prod_{i=1}^n f(x_i; \theta) = C(\theta) h(x_1, x_2, \dots, x_n) \exp\{b_1(\theta) T_1(x_1, x_2, \dots, x_n) + b_2(\theta) T_2(x_1, x_2, \dots, x_n)\}$$

则  $(T_1, T_2)$  是  $\theta = (\theta_1, \theta_2)$  的充分完备统计量

★ **Lehmann-Scheffe 定理：**

若  $T$  是  $\theta$  的充分完备统计量， $\theta$  是  $\theta$  的一个无偏估计，则  $\theta^* = E(\theta|T)$  为  $\theta$  的惟一的 UMVUE

★ **UMVUE 的求解步骤：**

① 求出参数  $\theta$  的充分完备统计量  $T$

② 求出  $ET = g(\theta)$ ，则  $\theta = g^{-1}(T)$  是  $\theta$  的一个无偏估计

或求出一个无偏估计，然后改写成用  $T$  表示的函数

③ 综合,  $E[g^{-1}(T)|T] = g^{-1}(T)$  是  $\theta$  的 **UMVUE**

或者: 求出  $\theta$  的矩估计或 **ML** 估计, 再求效率, 为 1 则必为 **UMVUE**

例: 设样本  $X_1, X_2, \dots, X_n$  是来自  $B(1, p)$ , 求  $p$  的 **UMVUE**

解: (1) 由上例知,  $T = \sum_{i=1}^n X_i \sim B(n, p)$  为充分完备统计量 (也是指数族分布), 且  $X_1$  为  $p$  的无偏估计。由 **Lehmann-Scheffe** 定理,  $p$  的 **UMVUE** 为

$$E(X_1 | T) = E(X_1 | \sum_{i=1}^n X_i) = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$$

例: 设样本  $X_1, X_2, \dots, X_n$  是来自  $N(\theta, 1)$ , 求  $\theta$  的 **UMVUE**

解:  $T = \bar{X} \sim N(\theta, 1/n)$  是充分完备统计量 (指数族分布), 且  $X_1$  为  $\theta$  的无偏估计。由 **Lehmann-Scheffe** 定理,  $\theta$  的 **UMVUE** 为  $E(X_1 | T)$ 。

由于  $\begin{pmatrix} X_1 \\ \bar{X} \end{pmatrix} \sim N\left(\begin{pmatrix} \theta \\ \theta \end{pmatrix}, \begin{pmatrix} 1 & \frac{1}{n} \\ \frac{1}{n} & \frac{1}{n} \end{pmatrix}\right)$ , 故

$$E(X_1 | T) = E(X_1 | \bar{X}) = \theta + \frac{\text{Cov}(X_1, \bar{X})}{D\bar{X}}(\bar{X} - \theta)$$

$$= \theta + (\bar{X} - \theta) = \bar{X}$$

即  $\bar{X}$  为  $\theta$  的 **UMVUE**。