

★最优势检验

设 X_1, \dots, X_n 是总体 $X \sim f(x, \theta) (\theta \in \Theta)$ 的一个样本，考虑假设

$$H_0: \theta \in \Theta_0 \leftrightarrow H_1: \theta \in \Theta_1$$

X_1, \dots, X_n 的取值范围 $S_n = W \cup W^c$ ，这里 W 为假设检验的拒绝域。

检验函数：

$$\phi(x_1, \dots, x_n) = \begin{cases} 1, & (x_1, \dots, x_n) \in W \\ 0, & (x_1, \dots, x_n) \notin W \end{cases} = 1_{\{(x_1, \dots, x_n) \in W\}}$$

检验的势函数为

$$g(\theta) = E_\theta(\phi(x_1, \dots, x_n)) = \begin{cases} \alpha(\theta), & \theta \in \Theta_0, \\ 1 - \beta(\theta), & \theta \in \Theta_1, \end{cases}$$

定义：当样本容量 n 固定时，检验法 ϕ_1 与 ϕ_2 的势分别为 $g_1(\theta), g_2(\theta)$ ，水平均为 α (i.e. $\sup_{\theta \in \Theta_0} g_1(\theta) \leq \alpha, \sup_{\theta \in \Theta_0} g_2(\theta) \leq \alpha$)，若 $\forall \theta \in \Theta$ ，均有

$$g_1(\theta) \geq g_2(\theta)$$

则称 ϕ_1 比 ϕ_2 的更有效。

若水平为 α 的检验法中， ϕ_1 比一切水平为 α 的检验法都有效，则称 ϕ_1 是水平为 α 的最优势检验。

一般而言，寻找最优势检验比较困难。有一个比较好的例子是似然比检验。

★似然比检验（简单假设对简单假设）

设 X_1, \dots, X_n 是总体 $X \sim f(x, \theta) (\theta \in \Theta)$ 的一个样本，考虑简单假设对简单假设的问题

$$H_0: \theta = \theta_0 \leftrightarrow H_1: \theta = \theta_1$$

定义似然比

$$\lambda(x_1, x_2, \dots, x_n) = \frac{L(x_1, x_2, \dots, x_n, \theta_1)}{L(x_1, x_2, \dots, x_n, \theta_0)} = \prod_{i=1}^n \frac{f(x_i, \theta_1)}{f(x_i, \theta_0)}$$

检验的拒绝域为

$$W = \{(x_1, x_2, \dots, x_n) : \lambda(x_1, x_2, \dots, x_n) \geq k\} \quad (k \text{ 待定})$$

定理 (Neyman-Pearson 引理) 设 X_1, \dots, X_n 是总体 $X \sim f(x, \theta) (\theta \in \Theta)$, 对

$$H_0 : \theta = \theta_0 \leftrightarrow H_1 : \theta = \theta_1$$

ϕ 是其似然比检验法, 若检验法 ϕ 与 $\tilde{\phi}$ 的势分别为 $g(\theta), \tilde{g}(\theta)$ (水平为 α) 满足 $\tilde{g}(\theta_0) \leq g(\theta_0)$, 则 $\tilde{g}(\theta_1) \leq g(\theta_1)$.

即若似然比检验的水平为 α (i.e. $g(\theta_0) = \alpha$), 则对任一水平为 α 的检验 $\tilde{\phi}$, 若 $\tilde{g}(\theta_0) \leq \alpha$, 则似然比检验 ϕ 为最优势检验。

例 1: 设 X_1, \dots, X_n 是 $N(\mu, \sigma^2)$ (σ 已知) 的一个样本, 检验假设

$$H_0 : \mu = \mu_0 \leftrightarrow H_1 : \mu = \mu_1$$

其中 $\mu_1 > \mu_0$

解: 似然比

$$\begin{aligned} \lambda(x_1, x_2, \dots, x_n) &= \frac{L(x_1, x_2, \dots, x_n, \mu_1)}{L(x_1, x_2, \dots, x_n, \mu_0)} \\ &= \frac{\left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n \exp\left\{-\sum_{i=1}^n \frac{(x_i - \mu_1)^2}{2\sigma^2}\right\}}{\left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n \exp\left\{-\sum_{i=1}^n \frac{(x_i - \mu_0)^2}{2\sigma^2}\right\}} \\ &= \exp\left\{n\bar{x}\left(\frac{\mu_1 - \mu_0}{\sigma^2}\right) - \frac{n(\mu_1^2 - \mu_0^2)}{2\sigma^2}\right\} \end{aligned}$$

当 H_0 为真时

$$\lambda(x_1, x_2, \dots, x_n) \geq k \Rightarrow \bar{x} \geq \frac{\ln k + \frac{n(\mu_1^2 - \mu_0^2)}{2\sigma^2}}{n(\frac{\mu_1 - \mu_0}{\sigma^2})}$$

$$\Rightarrow \frac{\bar{x} - \mu_0}{\frac{\sigma}{\sqrt{n}}} \geq \frac{\sigma \ln k}{\sqrt{n}(\mu_1 - \mu_0)} + \frac{\sqrt{n}(\mu_1 - \mu_0)}{2\sigma} \triangleq C$$

拒绝域为

$$W = \{(x_1, x_2, \dots, x_n) : \lambda(x_1, x_2, \dots, x_n) \geq k\}$$

$$= \{(x_1, x_2, \dots, x_n) : \frac{\bar{x} - \mu_0}{\frac{\sigma}{\sqrt{n}}} \geq C\}$$

$$= \{(x_1, x_2, \dots, x_n) : \frac{\bar{x} - \mu_0}{\frac{\sigma}{\sqrt{n}}} \geq u_{1-\alpha}\}$$

是最优势检验。

例 2: 设 X_1, \dots, X_n 是 $E(\frac{1}{\theta})$ (σ 已知) 的一个样本, 检验假设

$$H_0: \theta = \theta_0 \leftrightarrow H_1: \theta = \theta_1$$

其中 $\theta_1 < \theta_0$

解: 似然比

$$\lambda(x_1, x_2, \dots, x_n) = \frac{L(x_1, x_2, \dots, x_n, \theta_1)}{L(x_1, x_2, \dots, x_n, \theta_0)}$$

$$= (\frac{\theta_0}{\theta_1})^n \exp\{-(\frac{1}{\theta_1} - \frac{1}{\theta_0}) \sum_{i=1}^n x_i\}$$

$$\lambda(x_1, x_2, \dots, x_n) \geq k$$

$$\Leftrightarrow \frac{2}{\theta_0} \sum_{i=1}^n x_i \leq \frac{2}{\theta_0} (\frac{1}{\theta_1} - \frac{1}{\theta_0})^{-1} (n \ln \frac{\theta_0}{\theta_1} - \ln k) \triangleq C$$

$$\text{由于 } T \triangleq \frac{2}{\theta_0} \sum_{i=1}^n X_i \sim \chi^2(2n)$$

最优势检验的拒绝域为 $W = \{(x_1, x_2, \dots, x_n) : T \leq \chi_\alpha^2(2n)\}$ 。

★广义似然比检验（复合假设）

$$H_0 : \theta \in \Theta_0 \leftrightarrow H_1 : \theta \in \Theta_1 = \Theta - \Theta_0$$

广义似然比

$$\lambda(x_1, x_2, \dots, x_n) = \frac{\sup_{\theta \in \Theta} L(x_1, x_2, \dots, x_n, \theta)}{\sup_{\theta \in \Theta_0} L(x_1, x_2, \dots, x_n, \theta)}$$

拒绝域形式：

$$W = \{(x_1, x_2, \dots, x_n) : \lambda(x_1, x_2, \dots, x_n) \geq C\}$$

$$P(\lambda(X_1, X_2, \dots, X_n) \geq C) \leq \alpha, \forall \theta \in \Theta_0 (\text{under } H_0)$$

例 3 例 1：设 X_1, \dots, X_n 是 $N(\mu, \sigma^2)$ （ μ, σ 均未知）的一个样本，求

$$H_0 : \mu = \mu_0 \leftrightarrow H_1 : \mu = \mu_1$$

的广义似然比检验。

解：记 $\theta = (\mu, \sigma), \Theta_0 = \{(\mu_0, \sigma) : \sigma^2 > 0\}, \Theta = \{(\mu, \sigma) : \mu \in R, \sigma^2 > 0\}$

$$\begin{aligned} \lambda(x_1, x_2, \dots, x_n) &= \frac{\sup_{\theta \in \Theta} L(x_1, x_2, \dots, x_n, \theta)}{\sup_{\theta \in \Theta_0} L(x_1, x_2, \dots, x_n, \theta)} \\ &= \frac{L(x_1, x_2, \dots, x_n, \bar{x}, \frac{n-1}{n} s^2)}{L(x_1, x_2, \dots, x_n, \mu_0, \sigma^2)} = \left[\frac{\sum_{i=1}^n (x_i - \mu_0)^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right]^{\frac{n}{2}} \\ &= \left(1 + \frac{t^2}{n-1} \right)^{\frac{n}{2}} \quad t = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}} \end{aligned}$$

$$\{\lambda(x_1, x_2, \dots, x_n) \geq C\} = \{|t| \geq d\}$$

$$C = (1 + \frac{\alpha^2}{n-1})^{\frac{n}{2}}, d = t_{1-\frac{\alpha}{2}}(n-1)$$

$$\Rightarrow W = \{(x_1, x_2, \dots, x_n) : |t| \geq t_{1-\frac{\alpha}{2}}(n-1)\}$$

与以前的双侧检验一致。

★Bayes 检验

设 X_1, \dots, X_n 是总体 $X \sim f(x, \theta) (\theta \in \Theta)$ 的一个样本，考虑假设

$$H_0 : \theta \in \Theta_0 \leftrightarrow H_1 : \theta \in \Theta_1 = \Theta - \Theta_0$$

Bayes 检验的思想：在得到 θ 的后验分布后，计算此两个假设下的后验概率

$$\alpha_0 = P(H_0 | x_1, \dots, x_n) = P(\theta \in \Theta_0 | x_1, \dots, x_n)$$

$$\alpha_1 = P(H_1 | x_1, \dots, x_n) = P(\theta \in \Theta_1 | x_1, \dots, x_n)$$

称 $\frac{\alpha_0}{\alpha_1}$ 为后验概率比 (Odds)。

检验准则 (Jeffreys 准则)

(1) $\frac{\alpha_0}{\alpha_1} < 1$, 则拒绝 H_0 , 接受 H_1 ;

(2) $\frac{\alpha_0}{\alpha_1} > 1$, 则接受 H_0 ;

(1) $\frac{\alpha_0}{\alpha_1} < 1$, 不宜做判断。

先验概率比:

$$\frac{\pi_0}{\pi_1} = \frac{P_\pi(H_0)}{P_\pi(H_1)} = \frac{P_\pi(\theta \in \Theta_0)}{P_\pi(\theta \in \Theta_1)}$$

考虑后验概率比与先验概率比之间的关系，需要引入 H_0 对 H_1 的 Bayes 因子

$$B^\pi(x_1, \dots, x_n):$$

$$B^\pi(x_1, \cdots, x_n) = \frac{\alpha_0 / \alpha_1}{\pi_0 / \pi_1}$$

实际上，
$$B^\pi(x_1, \cdots, x_n) = \frac{f(x_1, \cdots, x_n | H_0)}{f(x_1, \cdots, x_n | H_1)}$$

其中 $f(x_1, \cdots, x_n | H_i) = \int_{\Theta_i} f(x_1, \cdots, x_n | \theta) \pi_i(\theta) d\theta \ (i = 0, 1)$ 为边际似然。

这里，我们有

$$\begin{aligned} \frac{\alpha_0}{\alpha_1} &= \frac{P(H_0 | x_1, \cdots, x_n)}{P(H_1 | x_1, \cdots, x_n)} = \frac{P_\pi(H_0)}{P_\pi(H_1)} B^\pi(x_1, \cdots, x_n) \\ &= \frac{\pi_0}{\pi_1} B^\pi(x_1, \cdots, x_n) \end{aligned}$$

$$\alpha_0 = P(H_0 | x_1, \cdots, x_n) = [1 + \frac{\pi_1}{\pi_0} B^\pi(x_1, \cdots, x_n)]^{-1}$$

先验概率确定后， $B^\pi(x_1, \cdots, x_n)$ 越大， α_0 越大，越偏向于接受 H_0 。

注：Jeffreys 准则（Bayes 因子）

B^π	可信强度（接受 H_0 的强度）
1:1 至 3:1	不值一提（Barely worth mentioning）
3:1 至 10:1	实质性的（Substantial）
10:1 至 30:1	强（Strong）
30:1 至 100:1	非常强（Very strong）
大于 100:1	决定性的（Decisive）

B^π 值小于 1 的，正好反过来（接受 H_1 的强度）。

情形 1：简单假设对简单假设

$$H_0 : \theta = \theta_0 \leftrightarrow H_1 : \theta = \theta_1$$

此时

$$\alpha_0 = P(\theta = \theta_0 | x_1, \dots, x_n) = \frac{\pi_0 f(x_1, \dots, x_n | \theta_0)}{\pi_0 f(x_1, \dots, x_n | \theta_0) + \pi_1 f(x_1, \dots, x_n | \theta_1)}$$

$$\alpha_1 = P(\theta = \theta_1 | x_1, \dots, x_n) = \frac{\pi_1 f(x_1, \dots, x_n | \theta_1)}{\pi_0 f(x_1, \dots, x_n | \theta_0) + \pi_1 f(x_1, \dots, x_n | \theta_1)}$$

故

$$\frac{\alpha_0}{\alpha_1} = \frac{\pi_0}{\pi_1} \frac{f(x_1, \dots, x_n | \theta_0)}{f(x_1, \dots, x_n | \theta_1)}$$

故 Bayes 因子

$$B^\pi(x_1, \dots, x_n) = \frac{f(x_1, \dots, x_n | \theta_0)}{f(x_1, \dots, x_n | \theta_1)} \quad (\text{即似然比}) \quad \text{与先验分布无关。}$$

情形 2: 复合假设对复合假设

$$H_0: \theta \in \Theta_0 \leftrightarrow H_1: \theta \in \Theta_1$$

设 θ 的先验分布为 $\pi(\theta)$, 则先验概率

$$\pi_0 = P_\pi(H_0) = P_\pi(\theta \in \Theta_0)$$

$$\pi_1 = P_\pi(H_1) = P_\pi(\theta \in \Theta_1)$$

先将先验分布 $\pi(\theta)$ 进行分解, 使得其支撑集在 Θ_0 和 Θ_1 上, 记

$$g_0(\theta) = \frac{\pi(\theta)}{\pi_0} 1_{\Theta_0}(\theta)$$

$$g_1(\theta) = \frac{\pi(\theta)}{\pi_1} 1_{\Theta_1}(\theta)$$

此时先验分布 $\pi(\theta) = \pi_0 g_0(\theta) + \pi_1 g_1(\theta)$, 于是

$$\begin{aligned}\frac{\alpha_0}{\alpha_1} &= \frac{P(\theta \in \Theta_0 | x_1, \dots, x_n)}{P(\theta \in \Theta_1 | x_1, \dots, x_n)} = \frac{\int_{\Theta_0} f(x_1, \dots, x_n | \theta) \pi(\theta) d\theta}{\int_{\Theta_1} f(x_1, \dots, x_n | \theta) \pi(\theta) d\theta} \\ &= \frac{\int_{\Theta_0} f(x_1, \dots, x_n | \theta) \pi_0 g_0(\theta) d\theta}{\int_{\Theta_1} f(x_1, \dots, x_n | \theta) \pi_1 g_1(\theta) d\theta}\end{aligned}$$

故有

$$B^\pi(x_1, \dots, x_n) = \frac{\alpha_0 / \alpha_1}{\pi_0 / \pi_1} = \frac{\int_{\Theta_0} f(x_1, \dots, x_n | \theta) g_0(\theta) d\theta}{\int_{\Theta_1} f(x_1, \dots, x_n | \theta) g_1(\theta) d\theta} \quad (\text{加权似然比})$$

情形 3: 简单假设对复合假设:

$$H_0: \theta = \theta_0 \leftrightarrow H_1: \theta \neq \theta_0$$

解: 记 $\Theta_0 = \{\theta_0\}, \Theta_1 = \Theta - \{\theta_0\}$

$$P_\pi(\theta = \theta_0) = \pi_0 > 0 \quad (\text{依据经验确定})$$

对于 $\Theta_1 = \Theta - \{\theta_0\}$ 上的分布, 我们可以给一个正常的密度函数然后进行放缩。这样我们的先验就变成了 $\pi(\theta) = \pi_0 1_{\Theta_0}(\theta) + (1 - \pi_0) g_1(\theta) 1_{\Theta_1}(\theta)$

后验分布为

$$\pi(\theta | x_1, \dots, x_n) \propto \pi_0 f(x_1, \dots, x_n | \theta_0) I_{\Theta_0}(\theta) + \pi_1 g_1(\theta) f(x_1, \dots, x_n | \theta) I_{\Theta_1}(\theta)$$

$$\frac{\alpha_0}{\alpha_1} = \frac{P(\theta = \theta_0 | x_1, \dots, x_n)}{P(\theta \in \Theta_1 | x_1, \dots, x_n)} = \frac{\pi_0 f(x_1, \dots, x_n | \theta)}{\pi_1 \int_{\Theta_1} g_1(\theta) f(x_1, \dots, x_n | \theta) d\theta}$$

$$B^\pi(x_1, \dots, x_n) = \frac{f(x_1, \dots, x_n | \theta)}{\int_{\Theta_1} f(x_1, \dots, x_n | \theta) g_1(\theta) d\theta} \quad \text{与先验分布无关。}$$

检验可用 Jeffreys 准则 (Bayes 因子情形) 进行。